

TREBALL DE FI DE GRAU
MATEMÀTICA COMPUTACIONAL I ANALÍTICA DE DADES
UNIVERSITAT AUTÒNOMA DE BARCELONA



ANÀLISI DE LES REPRESENTACIONS INTERNES DE LES XARXES
NEURONALS CONVOLUCIONALS

Víctor Benito Segura

Tutoritzat per: Maria Vanrell Martorell i Guillem Arias Bedmar

21/06/2024

Resum

La intel·ligència artificial ha revolucionat la nostra societat aconseguint fites que semblaven impossibles. Al capdavant d'aquest avenç hi ha les xarxes neuronals, models que emulen el funcionament del cervell humà per aprendre característiques rellevants a partir de les dades. Les Xarxes Neuronals Convolucionals (CNN*), en particular, han destacat en el camp de la visió per computador, essent imprescindibles en aplicacions com ara la detecció d'objectes, la conducció autònoma o la classificació d'imatges.

Malgrat l'èxit aconseguit, el funcionament intern de les CNNs segueix sent incert. Aquest fet ha donat lloc a un camp de recerca específic en IA* dedicat a comprendre i explicar millor com aquestes xarxes obtenen tants bons resultats.

En aquest projecte seguirem aquesta línia de treball i ens centrarem en entendre el comportament de les neurones a nivell individual. Per fer-ho, modelitzarem la selectivitat de les neurones a característiques concretes de les imatges. Aquest procés el realitzarem mitjançant la generació d'imatges amb funcions bàsiques: sigmoïdes i gaussianes, i les seves derivades.

Seguidament, buscarem els paràmetres d'aquestes funcions que maximitzin l'activació de les neurones individualment. Més endavant, definirem un algorisme d'optimització que permeti cercar els paràmetres que maximitzen l'activació de cada neurona. Finalment definirem un conjunt d'eines d'ordenació i classificació de les neurones que ens permetin entendre el comportament de les neurones a cada capa. Per acabar, aplicarem el mètode desenvolupat a analitzar la xarxa VGG-16 i en comentarem els resultats.

Aquest projecte pot ajudar a facilitar la comprensió de les xarxes neuronals convolucionals i a millorar futures implementacions pràctiques.

Abstract

Artificial intelligence has revolutionized our society by achieving milestones that seemed impossible. At the forefront of this advance are neural networks, models that emulate the functioning of the human brain to learn relevant characteristics from data. Convolutional Neural Networks (CNN*), in particular, have excelled in the field of computer vision, being essential in applications such as object detection, autonomous driving or image classification.

This great success is often linked to a lack of knowledge about the internal workings of CNNs and how they achieve such impressive results. This project aims to explain the operation of these networks, through the parameterization of basic functions: sigmoid and Gaussian, and their derivatives, focusing on the activation of neurons individually. Analyzing which images activate the neurons of a network the most will allow us to better understand what the model is learning in each of its layers. To achieve this, a method generating simple images will be built that describe their shape and color from a set of interpretable parameters. The Simulated Annealing optimization algorithm will then be used to search for parameters that maximize the activation of each neuron. Finally, a set of tools for sorting and classifying the neurons of each layer of the VGG-16 network will be defined based on the parameters found with the algorithms defined above. This understanding can not only improve the design of future networks, but also increase confidence in their practical applications.

Keywords: Xarxes Neuronals Convolucionals, paràmetres, CNN, activació, sigmoïde, gaussiana, Simulated Annealing, VGG-16.

Índex

1	Motivació	3
2	Objectius	3
3	Conceptes bàsics i Treballs relacionats	3
3.1	Xarxes Neuronals Convolucionals	3
3.2	Exemple de CNN: VGG16	5
3.3	Com s'entrenen les CNN: ImageNet	5
3.4	Anàlisi individual de les Neurons	5
4	Generació d'imatges simples	7
4.1	Formes basades en la Sigmoide	7
4.1.1	Sigmoide 1D	7
4.1.2	Sigmoide 2D	7
4.1.3	Rotació	8
4.2	Formes basades en la Gaussiana	8
4.2.1	Gaussiana 1D	8
4.2.2	Gaussiana 2D	9
4.2.3	Rotació	9
4.3	Càlcul de les Derivades	10
4.3.1	Sobel	10
4.3.2	Efectes de vorera	10
5	Cerca d'Activacions màximes	11
5.1	Consideracions computacionals prèvies	11
5.2	Pas 1: Cerca <i>Grid</i>	11
5.2.1	Paràmetres de forma	11
5.2.2	Selectivitat al color	13
5.2.3	Paràmetres de color	13
5.3	Pas 2: Cerca iterativa	14
5.3.1	Simulated Annealing	14
5.4	Resultats de l'optimització	15
6	Classificació i ordenació de les neurones	17
6.0.1	Mètode de classificació:	17
6.0.2	Mètode d'ordenació:	18
6.1	Resultats de l'ordenació i classificació de neurones	18
7	Conclusions generals i vies de continuació	21
8	Agraïments	21
9	Apèndix	23
9.1	Comparació Imatges generades vs Neuron Feature	23
9.2	Enllaç al codi del projecte	24

1 Motivació

Les Xarxes Neuronals Convolucionals (CNN) han assolit avenços molt importants en una gran varietat d'àrees en els darrers anys, des de la conducció autònoma fins a la detecció de persones o el diagnòstic clínic. Tot i això, sovint, aquests grans resultats de les CNN venen acompanyats d'un desconeixement sobre el seu funcionament intern i com aconsegueixen realitzar de manera tan brillant les diferents tasques.

Aquest treball té com a objectiu explorar per a quines característiques s'activen les neurones de la xarxa a nivell individual. Aquest fet pot ajudar a entendre més profundament els processos interns de les CNN i permetre millorar el desenvolupament de futures aplicacions i tècniques relacionades.

2 Objectius

Les capes de les xarxes convolucionals que s'han entrenat per resoldre tasques visuals, com ara el reconeixement d'objectes, presenten una organització interna que fa que cada neurona sigui selectiva a una característica específica de les imatges. Hi ha neurones que s'activen per contorns en una determinada orientació independentment del seu color, i neurones que s'activen per regions de la imatge d'un determinat color, independentment de la seva forma.

Examinar totes aquestes propietats de les neurones de manera global en una xarxa que té milers de neurones és molt complicat. Aquesta tasca es podria simplificar si poguéssim automatitzar la descripció dels tipus de neurones que té una xarxa entrenada. Per tal de poder indexar i ràpidament agrupar les neurones que comparteixen alguna propietat.

L'objectiu principal d'aquest treball anirà en aquesta línia. Es persegueix la creació d'un sistema de generació d'imatges que permeti trobar quines són les característiques que activen més cadascuna de les neurones de les diferents capes d'una Xarxa Neuronal, amb la intenció que aquest procediment sigui automàtic i el més general possible. Així doncs, els sub-objectius que es proposen són els següents:

Objectiu 1 Construir un mètode generador d'imatges simples que descriguin la seva forma i el seu color a partir d'un conjunt de paràmetres interpretables.

Objectiu 2 Dissenyar un algorisme d'optimització que permeti cercar les imatges simples que maximitzen l'activació d'una neurona.

Objectiu 3 Definir un conjunt d'eines d'ordenació i classificació de les neurones de cada capa d'una CNN a partir dels paràmetres trobats amb els algorismes definits als objectius anteriors.

3 Conceptes bàsics i Treballs relacionats

Abans d'explicar els mètodes implementats i mostrar els resultats obtinguts, presentarem breument alguns conceptes bàsics i farem un cop d'ull als treballs relacionats publicats. Primerament, explicarem què és una xarxa neuronal convolucional (CNN), com s'organitza internament i com s'entrena. Seguidament, enunciaré alguns treballs previs que han estudiat el comportament de les xarxes neuronals mitjançant l'anàlisi individual de les activacions de les neurones.

3.1 Xarxes Neuronals Convolucionals

Les Xarxes Neuronals Artificials[1], o **Artificial Neural Networks (ANNs)**, són sistemes de processament computacionals inspirats en el funcionament dels sistemes nerviosos, com ara el cervell humà. Aquestes xarxes estan constituïdes per un gran nombre de nodes computacionals interconnectats, anomenats neurones, que col·laboren per processar informació i aprendre de les entrades amb l'objectiu d'optimitzar la sortida final. L'estructura bàsica d'una Xarxa Neuronal Artificial es mostra a la següent figura:




Figura 1: Exemple d'estructura d'una xarxa neuronal bàsica

La principal diferència entre les CNNs i les ANNs tradicionals és que les CNNs es fan servir majoritàriament en el camp de reconeixement de patrons d'imatges. Això es degut al fet que cada neurona té associada una operació de convolució amb un filtre espacial, que li permet ser activada quan a la imatge d'entrada hi ha un patró que coincideix amb la forma per a la que ha estat entrenat el filtre.

Per poder entrenar una CNN necessitem conjunts de dades comuns de referència per fer l'aprenentatge automàtic. Un exemple és la base de dades MNIST de dígitos manuscrits que s'ha utilitzat per entrenar xarxes capaces de classificar caràcters. A la figura 2 mostrem un exemple d'una imatge de MNIST i indiquem alguns patrons parcials que són utilitzats per la xarxa per acabar identificant el número 4. Les CNNs tenen una estructura jeràrquica en que a través de la composició de formes a diferents nivells acaben identificant patrons més complexos. A les capes més profundes s'aprenen patrons globals de les imatges que acaben representant tots els píxels de la imatge. En canvi, a les capes convolucionals menys profundes es representen patrons locals de la mida de la finestra del filtre associat a cada neurona. Les neurones de les capes intermèdies aprenen a activar-se per formes locals que acabaran contribuint a la identificació d'un caràcter en global com podem veure a la figura[2]:



Figura 2: Exemple de detecció de patrons en imatges a una imatge MNIST.

Aquest aprenentatge a través de patrons locals dota a les xarxes convolucionals de dues propietats molt interessants:

Invariants la translació : les característiques que s'aprenen són invariants a la translació. És a dir, si una CNN reconeix un patró a la part inferior de la imatge, pot reconèixer aquest mateix patró posteriorment a una altra posició. Aquesta és una propietat derivada de l'operació de convolució.

Composició jeràrquica : les primeres capes poden aprendre característiques bàsiques com contorns i les capes més avançades combinar aquestes característiques per formar formes més diverses com podem veure a la següent figura[2]:




Figura 3: Exemple de detecció de patrons jerarquitzada. Els contorns locals es combinen per detectar objectes com ulls o orelles que finalment s'agrupen per formar conceptes d'alt nivell com "gat"

3.2 Exemple de CNN: VGG16

En aquest treball, analitzarem la xarxa VGG-16 [3] que va sorgir al 2014 com a possible millora del model AlexNet. VGG-16 és un model molt eficaç i sobretot atractiu per la seva simplicitat. Conté 16 capes on es combinen: operacions amb filtres 3×3 , funcions d'activació ReLU per capturar la no-linearitat, operacions de pooling per reduir el nombre de paràmetres i finalment amb *Fully-Connected-Layers* i *Softmax* per predir la sortida.




Figura 4: Esquema de les capes d'un model VGG-16 [4]

VGG-16 assoleix un 93% de precisió al conjunt de test, fent servir la base de dades d'imatges, ImageNet, que conté més de 14 milions d'imatges etiquetades amb 1000 possibles categories d'objectes.

3.3 Com s'entrenen les CNN: ImageNet

L'ImageNet[5] va ser creada per l'investigadora Li Fei-Fei i el seu equip de la Universitat de Stanford al 2009. Seguint la corrent que el WordNet havia generat en la millora del processament del llenguatge natural van proposar la creació d'un conjunt de dades immenses, divers i d'alta qualitat, que permetés la millora dins del camp de la visió per computador. L'ImageNet conté imatges de diferents classes: animals, objectes, persones, paisatges, etc. Amb classes molt semblants com races de gos, amb imatges en diferents posicions, il·luminació, escala, soroll. Ràpidament es va convertir en un repte molt atractiu pels investigadors del sector que van generar nous models i els van entrenar amb l'ImageNet. Aquest projecte va permetre la creació de models molt utilitzats a l'actualitat que han contribuït a l'èxit del camp. Alguns d'aquests models són: Xception, VGG19, ResNet, MobileNet, DenseNet i els seus derivats. Així com el model que farem servir en aquest projecte: VGG-16.

3.4 Anàlisi individual de les Neurones

Com dèiem al principi del treball, l'entrenament d'aquestes CNNs amb aquest alt nombre de capes i de neurones ha donat molt bons resultats en moltes tasques visuals, però el principal problema és la incapacitat d'entendre i de predir quina serà la resposta d'una xarxa entrenada. Això ha obert un camp de recerca que persegueix analitzar i entendre tota aquesta solvència. Dins d'aquesta àrea de trobar aplicabilitat de les CNNs, una línia de recerca ha estat l'estudi de les neurones individualment, per intentar entendre el comportament global a partir de la comprensió de cada una de les parts.

Seguint l'exemple del MNIST que hem vist a la introducció, una manera de comprovar l'efecte d'una imatge a una neurona concreta és mitjançant el concepte d'activació. Per cada neurona, hi ha un filtre determinat que recorre les imatges per tal de cercar un determinat patró. En aquesta imatge[2] en podem veure un exemple:




Figura 5: Resposta d'una imatge a un filtre 3x3

En aquest cas, podem veure com les regions de la imatge del zero que contenen una forma similar a la del filtre són més intenses a la imatge resposta.

Una manera de mesurar aquesta intensitat de la resposta és mitjançant l'activació. Per cada neurona, podem ordenar les imatges en funció de com l'han activada. D'aquesta manera, si observem quines imatges activen més una neurona ens podem fer una idea del que està aprenent la xarxa tot i no conèixer exactament els filtres utilitzats a cada neurona.

Entendre el funcionament de les xarxes neuronals convolucionals ha estat un tema primordial dins els departaments de recerca del Centre de Visió per Computador. Fins al moment, s'han fet diferents estudis per tal d'aclarir l'aprenentatge de les neurones dins la xarxa.

Conceptes clau:

- **Top Scoring** : Imatge trobada que més activa una determinada neurona d'una capa de la xarxa.
- **Neuron Feature (NF)** : Imatge mitjana de les 100 imatges Top Scoring que més activen una determinada neurona.
- **Índex de selectivitat**: Índex sobre la importància d'una determinada característica (color, forma, classe) sobre l'activació de la neurona.





Figura 6: Exemple de Neuron Feature (esquerra) i de les 100 Top Scoring Images (dreta) per la neurona 0 de la capa 0

En aquest treball[6] s'han incorporat dues mesures de selectivitat a les neurones:

- **Selectivitat al color**: índex sobre la importància del color a la neurona.
- **Selectivitat a la classe**: índex sobre la importància de la classe a la neurona.

Un altre projecte molt interessant [7] mostra les diferents formes que aprèn una xarxa neuronal a les diferents capes:

Neurons in Conv1



Non Color Selective Neurons in Conv2




Figura 7: Ordenació de les neurones d'una xarxa neuronal per la seva forma i la seva selectivitat al color.

Aquesta ordenació representa exactament la motivació del nostre treball. No obstant, aquest refinament s'ha fet de manualment, fet que resulta molt tediós i poc generalitzable per altres xarxes. És per això que sorgeix la necessitat de poder realitzar aquesta mateixa feina de manera automàtica i general.

4 Generació d'imatges simples

Per assolir l'objectiu 1 necessitem dissenyar imatges simples amb funcions paramètriques que ens permetin entendre l'activació d'una neurona a partir dels paràmetres d'aquesta funció.

Per a generar imatges de formes simples farem servir dues famílies de funcions: la funció Sigmoidal i la funció de Gauss, així com les seves derivades. Amb aquestes funcions bàsiques podem generar una llarga família de formes simples on els paràmetres descriuen elements com ara l'orientació, la suavitat dels contorns o la freqüència espacial.

4.1 Formes basades en la Sigmoidal

Farem servir la funció sigmoidal per generar imatges lineals. És a dir, rectes orientades de diferents maneres, amb diferents contrastos i desplaçaments.

4.1.1 Sigmoidal 1D

En primer lloc, observem la definició de la funció sigmoidal bàsica en una dimensió:

$$f(z) = \frac{1}{1 + e^{-z}} \quad (1)$$




Figura 8: Funció sigmoidal bàsica

Seguidament, mostrem l'efecte dels diferents paràmetres de la funció. El pendent, que anomenarem (a) i el desplaçament que definirem amb la variable (b).

$$f(z, a, b) = \frac{1}{1 + e^{-a \cdot (z-b)}} \quad (2)$$




Figura 9: Diferents valors de pendent (a) i desplaçament (b) per una sigmoidal 1D

4.1.2 Sigmoidal 2D

Amb la finalitat de crear imatges a partir de la funció sigmoidal, utilitzarem la funció meshgrid[8]. Aquesta funció, genera un núvol de punts (x,y) dins d'un rang passat per paràmetre. Posteriorment, passarem aquest núvol de punts com a argument de la nostra funció sigmoidal en dues dimensions per generar la imatge resultant.

$$f(x, y, a, b) = \frac{1}{1 + e^{-a \cdot (x+y-b)}} \quad (3)$$

Com hem esmentat anteriorment, ens interessa obtenir rectes en diferents orientacions. A fi d'obtenir-ho, inclourem un nou paràmetre θ a la funció per tal de produir la rotació pertinent.

$$f(x, y, a, b, \theta) = \frac{1}{1 + \exp(-a \cdot (\text{rotated_}x + \text{rotated_}y))} \quad (4)$$

on:

$$\text{rotated_}x = x \cdot \cos(\theta) - (y - b) \cdot \sin(\theta)$$

$$\text{rotated_}y = x \cdot \sin(\theta) + (y - b) \cdot \cos(\theta)$$




Figura 10: Generació d'una imatge 2D amb la funció sigmoide original

4.1.3 Rotació

Per la naturalesa de la funció sigmoide, la projecció 2D sense rotació, és a dir, amb angle $\theta = 0$ correspon amb una imatge que mostra una recta de 45° 10. Per tal de comprendre correctament l'aprenentatge de les neurones i per no afegir ambigüitat, definirem la nostra funció sigmoide com una rotació de -45° de la funció sigmoide 2D original.




Figura 11: Generació d'una imatge 2D amb la funció sigmoide modificada

4.2 Formes basades en la Gaussiana

Amb les sigmoïdes i les seves derivades podem generar un gran ventall d'imatges. Tanmateix, no podem generar formes isotròpiques i això és un gran inconvenient ja que a la xarxa si que trobem neurones que s'activen per aquestes formes. Precisament amb l'objectiu de generar imatges no lineals com circumferències o el·lipses utilitzarem funcions gaussianes.

4.2.1 Gaussiana 1D

$$g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (5)$$

on:

- μ és la mitjana de la distribució.
- σ és la desviació estàndard de la distribució.




Figura 12: Gaussiana 1D amb $\mu = 0$ i $\sigma = 1$

A continuació mostrem un gràfic per veure el funcionament de la gaussiana per diferents valors de μ i σ




Figura 13: Diferents valors de μ i σ per una Gaussiana 1D

4.2.2 Gaussiana 2D

De la mateixa manera que hem fet amb la funció sigmoide, transformarem la funció en dues dimensions i construirem la imatge amb el núvol de punts generat pel meshgrid.

$$g(x, y) = Ae^{-\left(\frac{(x-\mu_x)^2}{2\sigma_x^2} + \frac{(y-\mu_y)^2}{2\sigma_y^2}\right)} \quad (6)$$

on A és l'amplitud.




Figura 14: Generació d'una imatge 2D amb la funció Gaussiana

4.2.3 Rotació

Finalment afegirem també rotació a la gaussiana. Per tal que no hi hagi ambigüitat definirem la gaussiana amb un seguit de normes:

- En els casos on $\sigma_x = \sigma_y$ no farem la rotació.
- Sempre considerarem que $\sigma_x > \sigma_y$ per no generar imatges repetides.

$$g(x, y) = Ae^{-\left(\frac{(\text{rotated}_x - \mu_x)^2}{2\sigma_x^2} + \frac{(\text{rotated}_y - \mu_y)^2}{2\sigma_y^2}\right)} \quad (7)$$

on:

$$\text{rotated}_x = (x - \mu_x) \cdot \cos(\theta) - (y - \mu_y) \cdot \sin(\theta)$$

$$\text{rotated}_y = (x - \mu_x) \cdot \sin(\theta) + (y - \mu_y) \cdot \cos(\theta)$$




Figura 15: Generació d'una imatge 2D amb la funció Gaussiana

4.3 Càlcul de les Derivades

Realitzar derivades espacials ens pot permetre generar formes més complexes a partir de les funcions bàsiques anteriors mantenint els mateixos paràmetres introduïts. És a dir, noves imatges útils per classificar imatges de la xarxa neuronal. Com per exemple, diverses línies o textures.

4.3.1 Sobel

Per calcular aquestes derivades utilitzarem l'operador diferencial Sobel[9], que és un operador altament utilitzat dins el camp del processament d'imatges per aproximar el gradient de la funció d'intensitat d'una imatge.

Filtre de Sobel a la
direcció x (horitzontal):

$$S_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

Filtre de Sobel a la
direcció y (vertical):

$$S_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

4.3.2 Efectes de vorera

A mesura que realitzem derivades amb l'operador Sobel es produeixen efectes de vorera, a causa de com fa l'escombrament el filtre a la imatge. Aquest fet produeix que els píxels exteriors tinguin una intensitat molt alta no desitjada i que la imatge derivada central baixi la seva intensitat.

Per tal de solucionar aquest problema realitzarem un augment dels píxels de la imatge en funció del nombre de derivades que vulguem realitzar. Seguidament, realitzarem les derivades corresponents i finalment retallarem la part central de la imatge per tal de retornar una imatge de la mateixa mida correctament derivada.




Figura 16: Visualització dels efectes de vorera per una imatge generada amb una sigmoide de mida 40×40 amb paràmetres $a=1$, $b=0$, $\theta=45$ i derivades $dx=6$, $dy=6$

5 Cerca d'Activacions màximes

A la secció anterior, hem proposat un mètode per generar imatges de formes simples mitjançant funcions bàsics. Ara, necessitem un mètode per poder cercar les imatges que maximitzen el valor d'activació de cada neurona dins l'espai de tot el conjunt d'imatges creat.

Per a resoldre aquest problema, aplicarem un algorisme de cerca local que busqui a tot l'espai d'imatges que generen els paràmetres. Per a cada conjunt de paràmetres, la funció heurística a optimitzar serà l'activació que provoca la imatge generada sobre la neurona que s'està analitzant. Per tant, per a cada neurona haurem d'aplicar l'algorisme de cerca sobre tot l'espai de paràmetres.

5.1 Consideracions computacionals prèvies

Inicialment, vam pensar d'estructurar la cerca generant uns paràmetres estàndards per inicialitzar un algorisme de cerca local. L'algorisme creava les diferents imatges a partir de la modificació dels paràmetres i guardava la combinació d'aquests si l'activació mesurada era superior a l'obtinguda anteriorment. Desafortunadament, aquest plantejament no va funcionar per dues raons principals:

- **Inicialització massa àmplia:** les diferents formes que podem generar amb les sigmoïdes i gaussianes tenen una variació considerable a nivell de paràmetres. Trobar una inicialització que ens permeti trobar màxims globals per imatges tan diverses no és gens fàcil. A més, els algorismes de cerca necessiten moltes iteracions per aconseguir arribar a activacions properes a les que genera la imatge Top Scoring de cada neurona.
- **Iteracions en paral·lel:** la dificultat de trobar una bona inicialització ve donada pel problema de calcular les activacions. Cada vegada que cerquem l'activació d'una imatge estem recorrent una xarxa VGG-16 amb tot el temps que això comporta. A més a més, com que els paràmetres depenen d'execucions anteriors, no és possible executar en paral·lel amb GPU. És per això, que aquest enfocament inicial no és viable i hem hagut d'investigar altres solucions.

Per tal de solucionar aquests problemes hem plantejat el problema des d'un altre punt de vista. Com que per capacitat de còmput no podem calcular activacions de manera iterativa, hem decidit utilitzar els processos d'execució paral·lels en el càlcul d'una primera inicialització. Això ho hem fet dissenyant un algorisme de cerca amb dos passos:

Pas 1. Cerca *Grid* : basada en generar un conjunt d'imatges amb un conjunt de paràmetres mostrejats de manera exhaustiva sobre l'espai de paràmetres com si projectéssim una quadrícula. A partir d'aquestes imatges calcularem les execucions en paral·lel fent servir les GPUs. Seguidament, farem servir una funció $\arg\max$ per trobar els paràmetres que produeixen les millors inicialitzacions.

Pas 2. Cerca iterativa : un cop hem trobat una bona inicialització aplicarem un algorisme de cerca local al voltant dels paràmetres de les imatges amb millors activacions. Hi ha diverses alternatives. En aquesta primera aproximació hem decidit treballar amb un *Simulated Annealing*.

En els següents apartats expliquem els detalls d'aquest algorisme.

5.2 Pas 1: Cerca *Grid*


En aquest primer pas, necessitem generar un conjunt d'imatges inicials amb un ventall reduït de valors dels paràmetres de les funcions. L'objectiu és produir primeres aproximacions suficientment bones sense sobrecarregar la memòria GPU. Això és possible ja que aquests paràmetres no són dependents i podem calcular les activacions de totes aquestes imatges de cop, en un sol recorregut de la VGG-16 per cada capa. Per cada neurona de cada capa, podem trobar les imatges que més activen aquella neurona i guardar-nos els paràmetres que les generen. Construïrem tants subconjunts d'imatges com capes tingui la nostra xarxa neuronal. La mida de les imatges generades als diferents subconjunts ve donada per la mida K de les imatges d'aquella capa.

5.2.1 Paràmetres de forma

Generarem un conjunt inicial d'imatges format per les diferents formes bàsiques de les funcions sigmoïdes i gaussianes. Aquestes imatges es generaran a partir del ventall de possibles valors que tindrà cadascun dels paràmetres de les funcions i que resumim a les següents taules. També il·lustrarem el comportament de cada paràmetre amb les següents graelles d'imatges.


Taula 1: Sigmoide

Paràmetre	Símbol	Valors conjunt d'imatges
Pendent	a	[0.1, 1.55, 3]
Desplaçament	b	[-3, -1.8, -0.6, 0.6, 1.8, 3]
Angle	θ	[0, 30, 60, 90, 120, 150, 180, 210, 240, 270, 300, 330]
Derivada d'x	dx	[0, 1, 2, 3, 4]
Derivada d'y	dy	[0, 1, 2, 3, 4]


 Figura 17: Exemple Grid Images basat en una funció sigmoide amb $a=1, b=0, \theta=45, dx=0, dy=0$

Taula 2: Gaussiana

Paràmetre	Símbol	Valors conjunt d'imatges
Centre de la gaussiana a l'eix x	μ_x	[-5, -2.5, 0, 2.5, 5]
Centre de la gaussiana a l'eix y	μ_y	[-5, -2.5, 0, 2.5, 5]
Desviació estàndard a l'eix x	σ_x	[0.10, 0.48, 0.86, 1.24, 1.62, 2.00]
Desviació estàndard a l'eix y	σ_y	[0.10, 0.48, 0.86, 1.24, 1.62, 2.00]
Derivada d'x	dx	[0, 1, 2, 3, 4]
Derivada d'y	dy	[0, 1, 2, 3, 4]


 Figura 18: Exemple Grid Images basat en una funció sigmoide amb $a=1, b=0, \theta=45, dx=0, dy=0$

Sinònims i funcions hash

Les imatges generades amb les funcions sigmoïdes, gaussianes i els paràmetres esmentats anteriorment, sovint generen imatges idèntiques. Això es deu a les simetries de les funcions. Concretament, sorgeixen a les primeres capes ja que el rang de paràmetres és més petit.

Per tal de no generar imatges idèntiques, que augmenten la dimensió i produeixen les mateixes activacions a les neurones, utilitzarem funcions Hash[10]. Les funcions Hash són una eina molt utilitzada en Criptografia per xifrar i desxifrar missatges.

En aquest projecte, les utilitzarem per cercar aquells paràmetres que generen les mateixes imatges. Buscarem coal·licions fortes entre els valors hash produïts pels valors matricials de les imatges.

Aquest fet ens servirà per dues raons principals:

- En primer lloc, podrem reduir l'espai d'imatges significativament.
- Per altra banda, ens ajudarà a entendre millors les relacions entre els paràmetres i poder esbrinar quins conjunts de paràmetres produeixen les mateixes imatges.

5.2.2 Selectivitat al color

Com hem pogut observar en els estudis previs, algunes neurones són molt selectives al color i d'altres no ho són tant i són més selectives a altres característiques com la forma.

El nostre conjunt de d'imatges inicial conté imatges en blanc i negre, que sovint no activen suficient algunes neurones. És per això que aprofitant l'índex de selectivitat al color, donarem color a les imatges de les neurones que superin un llindar establert. color.

5.2.3 Paràmetres de color

Amb l'objectiu d'acolorir les imatges, utilitzarem les imatges que més han activat una neurona (Top Scoring). Seguidament, farem servir un algorisme de clustering, KMeans[11], per trobar els dos colors més intensos de la imatge. Posteriorment farem una transformació de l'escala de grisos de les nostres imatges en blanc i negre, a l'escala que pren com a origen el color 1 trobat amb KMeans fins al color 2 obtingut. A la següent figura podem veure com transformem les imatges del nostre conjunt a color mitjançant els colors representatius de la imatge Top Scoring de la neurona.




Figura 19: Exemple del procés de donar color a una imatge en blanc i negre a partir dels colors representatius obtinguts amb KMeans de la imatge Top Scoring.

Després de transformar les imatges a color per les neurones que són selectives, tenim un conjunt d'imatges per cada neurona del qual en podem calcular les activacions. Per cada neurona mostrarem la imatge del Top Scoring i les cinc imatges trobades dins el nostre conjunt d'imatges que han produït una major activació:




Figura 20: Exemple dels resultats d'activació obtinguts pel conjunt d'imatges a la neurona 17 de la capa 2

5.3 Pas 2. Cerca iterativa

En aquest moment per cada neurona tenim cinc imatges, acolorides o no, que aproximen l'activació màxima de la neurona produïda per la imatge Top Scoring. Tot i així, aquestes imatges utilitzades són un subconjunt limitat dels valors dels paràmetres que produeixen les imatges. És per això que un cop trobades aquestes imatges properes, utilitzarem un algorisme de cerca local per tal d'optimitzar encara més el valor de l'activació.

5.3.1 Simulated Annealing

Simulated Annealing [12] és un algorisme de cerca local usat per solucionar problemes d'optimització. El punt fort de l'algorisme és que proporciona un mecanisme per escapar dels valors òptims locals permetent moviments d'escalada. És a dir, moviments que empitjoren el valor de la funció objectiu amb l'esperança de trobar un valor òptim global posteriorment.

L'algorisme rep el nom del recuit físic de sòlids, on aquests s'escalfen i es refreden lentament per assolir una configuració òptima. Aquest procés és similar a la cerca de mínims globals en problemes d'optimització discreta. L'algorisme accepta sempre solucions que milloren l'actual i, ocasionalment, accepta pitjors solucions per evitar quedar atrapat en mínims locals. La probabilitat d'acceptar solucions inferiors depèn d'un paràmetre de temperatura que decreix amb cada iteració. És a dir, inicialment es permeten més errors per mirar d'abordar diferents vies i quan la temperatura va disminuint, l'algorisme tendeix a concentrar-se en solucions òptimes globals. Inicialitzarem cinc Simulated Annealings, prenent com a paràmetres inicials els paràmetres de les cinc imatges del nostre conjunt d'imatges que més han activat la neurona. A més a més, inclourem els paràmetres RGB dels colors trobats per les imatges selectives al color. Finalment ens quedarem amb els paràmetres de la imatge que més activa la neurona d'aquestes cinc cerques.




Figura 21: Exemple de la cerca de màxims globals amb Simulated Annealing [yang2022research]

Finalment, podem observar els resultats del procés d'optimització amb Simulated Annealing per la mateixa neurona de la figura 20:




Figura 22: Exemple dels resultats d'optimització obtinguts amb Simulated Annealing a la neurona 17 de la capa 2

5.4 Resultats de l'optimització

Per tal d'avaluar el procés d'optimització de l'algorisme de cerca, presentarem els diferents resultats obtinguts:




Figura 23: Ajust de les neurones per les sis primeres capes. De color verd, l'ajust objectiu del Top Scoring, de color lila l'ajust obtingut amb el conjunt d'imatges i de color groc l'ajust obtingut amb l'algorisme d'optimització.

En aquest primer gràfic podem veure com l'algorisme d'optimització funciona de manera brillant a les dues primeres capes. L'ajust de les imatges obtingudes amb el mètode d'optimització, de color groc al gràfic, supera en la majoria de neurones a la millor activació obtinguda amb les imatges de la xarxa (Top Scoring). De la mateixa manera, podem veure que a mesura que aprofundim més a la xarxa, generem un pitjor ajust ja que no som capaços de representar imatges més complexes.

A continuació, mostrarem els resultats mitjans d'ajust per capa, que ens poden ajudar a resumir millor els resultats.




Figura 24: Ajust mitjà de les neurones de les sis primeres capes de la xarxa, pels diferents mètodes proposats.

Com ja havíem intuït amb el gràfic anterior, l'algorisme funciona perfectament per les primeres capes, però a mesura que incrementem la complexitat i augmentem la dimensió de les imatges, els resultats són més desfavorables.

Veient aquests resultats ens podem preguntar perquè produïm millors activacions que les imatges de la xarxa. Aquest fet el podem explicar millor a partir de la següent taula:

Taula 3: Ajust Mitjà per Capa

Capa	Ajust Mitjà Neurons No Selectives al Color	Ajust Mitjà Neurons Selectives al Color
0	0.9800	1.0903
1	0.8950	1.0510
2	0.7694	0.9536
3	0.7354	0.9111
4	0.5776	0.6992
5	0.4500	0.5713

Com podem observar, les activacions de les neurones en les que hem tractat el color. És a dir, aquelles que tenen una selectivitat alta al color, generen activacions mitjanes superiors que les neurones poc selectives al color. Aquest fet es deu a la inclusió dels valors RGB dels dos colors principals de la imatge com a paràmetres a optimitzar. Ja que d'aquesta manera podem generar moltes més combinacions d'un color de les que apareixen a la xarxa, aconseguint activacions superiors per determinades neurones on la selectivitat al color és alta.

Resultats satisfactoris: A continuació mostrarem alguns exemples on l'algorisme d'optimització ha funcionament sorprenentment bé:




Figura 25: Exemple d'un cas d'èxit d'optimització per cada una de les sis primeres capes de la xarxa

En tots aquests casos, de diferents capes, hem pogut aconseguir una activació superior a l'establerta amb les imatges de la xarxa. Podem comprovar com en aquestes neurones els colors són més intensos que en les imatges originals.

Resultats desfavorables: De la mateixa manera que hem fet pels casos favorables, mostrarem una neurona de cada capa que no hem pogut ajustar correctament per mirar d'analitzar quins han estat els errors:




Figura 26: Exemple d'un cas desfavorable d'optimització per cada una de les sis primeres capes de la xarxa

A partir d'aquests resultats, podem començar a descriure les debilitats de l'algorisme:

- En primer lloc, l'algorisme no és capaç d'ajustar correctament la forma per **imatges complexes** com podem observar a les diferents neurones.
- A més a més, en determinades neurones no aconseguim millorar gairebé res amb l'optimització l'activació obtinguda amb les imatges del Grid. Aquest fet es produeix quan, les millors imatges del nostre conjunt són molt semblants i **no aconseguim sortir del màxim local trobat** tal com podem veure a la següent figura.




Figura 27: Exemple de cas desfavorable on les millors imatges trobades al nostre conjunt d'imatges són similars.

6 Classificació i ordenació de les neurones

Un cop optimitzades les imatges que més activen les neurones de cada capa, ens interessa poder fer una ullada general al que ha après la xarxa ja que volem saber quines formes s'estan processant a cada etapa.

Els paràmetres establerts ens permeten ordenar les neurones en funció dels patrons que estan interioritzant. Per exemple, podem ordenar les imatges per angles per tal d'observar quins són els contorns que s'estan cercant, o pel nombre de derivades. Com que tenim els paràmetres de les funcions generades amb funcions simples i aquestes s'ajusten a les imatges processades per la xarxa, podem fer una ordenació de les imatges representatives de cada neurona de cada capa (NF) a partir dels nostres paràmetres.

Primerament, farem una visió detallada del que s'està aprenent a cada etapa. I comprovarem que les nostres imatges ajusten correctament la Neuron Feature. Ho farem, mostrant un gràfic amb totes les NF de les neurones de les capes, juntament amb la nostra imatge generada.³⁴

Observem com a les capes inicials, la xarxa aprèn a detectar contorns i posteriorment, formes bàsiques isotròpiques. A mesura que ens endinsem a les capes més profundes les formes són objectes complexes, fet que fa que les nostres prediccions d'imatges no ajustin suficientment.

Ara bé, aquesta manera d'observar les capes és molt general i no ens permet observar bé quines formes s'estan tractant i quines no, fet molt important si volem millorar el rendiment d'una determinada xarxa neuronal.

6.0.1 Mètode de classificació:

Classificarem les neurones de quatre diferents:

- **Per capa:** En primer lloc, separarem les neurones per capes per veure que està aprenent la xarxa a cada etapa.
- **Per funció generadora:** En segon lloc, dividirem les imatges en funció de si han estat generades amb sigmoïdes o gaussianes.
- **Per selectivitat al color:** A continuació separarem les imatges segons si són selectives al color o no. Cal remarcar que hem utilitzat un índex de selectivitat llindar de 0.2.
- **Per derivades:** Finalment, dividirem les imatges en funció de si provenen d'una funció derivada o no.

6.0.2 Mètode d'ordenació:

Per acabar, ordenarem cada subconjunt d'imatges en funció del paràmetre de l'angle. Fet que ens ajudarà a visualitzar les formes que es comprenen i també les absents.

Refinament: Com hem pogut constatar en els resultats dels algorismes d'optimització, sovint generem imatges que no representen la mateixa forma que la NF. Especialment a les capes més profundes. Si l'aproximació de la imatge no és bona, no té sentit utilitzar els seus paràmetres per descriure la NF, ja que no definiran la mateixa forma. És per això que per aquest anàlisi només mostrarem les imatges de les neurones que han obtingut un ajust superior a un llindar. Aquest llindar el reduïrem lleugerament per a capes més profundes per poder observar més neurones detalladament.

6.1 Resultats de l'ordenació i classificació de neurones

Capa 0: hem utilitzat un llindar de 0.8 i hem ajustat correctament 64 de les 64 imatges de la capa.




Figura 28: Classificació i ordenació de la capa 0

Ara podem observar clarament què està aprenent cada neurona. Podem veure com en aquesta primera capa, la VGG-16 aprèn contorns bàsics orientats de diferents maneres. Per altra banda, també podem constatar com algunes neurones s'encarreguen de processar colors bàsics de la xarxa en aquesta capa. Finalment, podem veure com comencen a aparèixer algunes derivades i formes més complexes.

Capa 1: hem utilitzat un llindar de 0.8 i hem ajustat correctament 59 de les 64 imatges de la capa.




Figura 29: Classificació i ordenació de la capa 1

Observem ràpidament com les neurones de la segona capa segueixen un aprenentatge similar a les de la primera: processant contorns orientats i colors simples. Tot i així, en aquesta capa podem veure com comencen a aparèixer formes isotròpiques i algunes derivades superiors.

Capa 2: hem utilitzat un llindar de 0.775 i hem ajustat correctament 70 de les 128 imatges de la capa.




Figura 30: Classificació i ordenació de la capa 2

En aquesta tercera capa, podem veure clarament com comencen a aparèixer imatges no lineals. Per altra banda, el nombre de neurones que processen formes similars a les gaussianes creix fortament. Podem visualitzar també com sorgeixen també gaussianes desplaçades i gaussianes no-isotròpiques rotades.

Capa 3: hem utilitzat un llindar de 0.775 i hem ajustat correctament 72 de les 128 imatges de la capa.




Figura 31: Classificació i ordenació de la capa 3

D'aquesta quarta capa, no podem extreure conclusions massa rellevants. Se segueixen els patrons d'aprenentatge de les neurones de la tercera capa. Tot i així, sí que podem observar més varietat de gaussianes derivades.

Capa 4: hem utilitzat un llindar de 0.75 i hem ajustat correctament 63 de les 256 imatges de la capa.




Figura 32: Classificació i ordenació de la capa 4

A la cinquena capa podem observar com la xifra de neurones descrites amb funcions derivades creix altament. També comprovem que les neurones que aconseguim ajustar correctament són majoritàriament gaussianes isotròpiques i orientacions complexes.

Capa 5: hem utilitzat un llindar de 0.70 i hem ajustat correctament 41 de les 256 imatges de la capa.




Figura 33: Classificació i ordenació de la capa 5

Finalment, farem l'anàlisi de la darrera capa processada. Observem com les neurones d'aquestes capes ja no processen contorns simples sinó contorns no lineals. A més a més, les neurones comencen a descriure objectes més complexos que no aconseguim ajustar bé amb les nostres funcions bàsiques.

Conclusions de l'anàlisi per capes: aquest anàlisi ens ha permès entendre de manera clara què aprenen les neurones de les diferents capes de la xarxa. Hem comprovat que les neurones de les primeres capes aprenen formes bàsiques. Aquest aprenentatge funciona de forma jeràrquica, de tal manera que la xarxa va processant formes cada cop més complexos fins arribar a comprendre els objectes.

Pel que fa al nostre mètode d'ordenació, hem vist com a les primeres capes som capaços d'ajustar la gran majoria de les neurones correctament. En canvi, a les capes més profundes, no és així. Aquest fet ens ha fet establir el valor d'ajust com a hiperparàmetre: un valor d'ajust molt exigent eliminarà moltes neurones que estan ajusten patrons correctament i un valor molt baix descriurà neurones erròniament.

Tot i els problemes esmentats, aquesta eina pot ser una bona aproximació per l'anàlisi de diferents xarxes neuronals i permet un gran marge de millora.

7 Conclusiones generals i vies de continuació

En aquest projecte hem desenvolupat una primera aproximació al problema de caracteritzar automàticament les formes bàsiques que activen les neurones d'una CNN. Aquesta aproximació l'hem realitzada mitjançant la generació d'imatges amb els paràmetres de les funcions sigmoïdes i gaussianes i les seves derivades. Seguidament, hem proposat un algorisme de cerca basat en dos passos: l'elaboració d'un espai d'imatges a través d'un ventall de paràmetres i l'optimització dels paràmetres amb l'algorisme de cerca local Simulated Annealing. Aquesta estratègia permet aprofitar l'execució en paral·lel de les CNN per tal d'optimitzar l'activació individual de cada neurona.

A més a més, hem utilitzat funcions hash per eliminar sinònims dins l'espai de paràmetres i hem plantejat un mètode per tractar el color que presenta moltes alternatives de millora. Per últim, hem analitzat els resultats obtinguts i hem presentat un mètode de classificació i ordenació automàtic de les neurones d'una xarxa que pot afavorir-ne la comprensió.

Aquest treball ha estat una aproximació preliminar al problema i s'han obert un bon conjunt de noves línies de recerca per atacar el problema que resumirem a continuació:

- Utilitzar funcions derivades de les sigmoïdes i gaussianes, com ara la suma o la multiplicació, per abordar formes més complexes.
- Estudiar l'hiperparàmetre lindar de la selectivitat al color per tal de millorar les activacions sense augmentar considerablement el temps de còmput.
- Assegurar que els paràmetres inicials del Simulated Annealing siguin prou diversos per tal de no quedar-nos encastats en màxims locals.
- Executar durant més iteracions el Simulated Annealing amb una temperatura més alta per evitar caure en mínims locals.
- Estudiar l'hiperparàmetre lindar de l'ajust per classificar i ordenar un conjunt de neurones representatives prou ampli.
- Provar el funcionament del mètode per altres xarxes Neuronals Convolucionals com Clic o VGG-19.

8 Agraïments

M'agradaria donar les gràcies a la Maria i a en Guillem, els tutors d'aquest treball, per tot el seu suport durant el projecte i per haver-me presentat el món de la recerca, dins d'un camp tant apassionant com les xarxes neuronals.

Finalment, voldria agrair també al Centre de Visió per Computador de Catalunya per deixar-me utilitzar les seves eines de còmput, sense aquests recursos no hagués estat possible realitzar aquest treball.

Referències

- [1] Keiron O'shea i Ryan Nash. "An introduction to convolutional neural networks". A: arXiv preprint arXiv:1511.08458 (2015).
- [2] Chollet Francois. Deep learning with Python. 2018.
- [3] Karen Simonyan i Andrew Zisserman. "Very deep convolutional networks for large-scale image recognition". A: arXiv preprint arXiv:1409.1556 (2014).
- [4] Will Nash, Tom Drummond i Nick Birbilis. "A review of deep learning in the study of materials degradation". A: npj Materials Degradation 2.1 (2018), pàg. 37.
- [5] Jia Deng et al. "Imagenet: A large-scale hierarchical image database". A: 2009 IEEE conference on computer vision and Ieee. 2009, pàg. 248 - 255.
- [6] Ivet Rafegas et al. "Understanding trained CNNs by indexing neuron selectivity". A: Pattern Recognition Letters 136 (2020), pàg. 318 - 325.
- [7] Ivet Rafegas i Maria Vanrell. "Color encoding in biologically-inspired convolutional neural networks". A: Vision research 151 (2018), pàg. 7 - 17.
- [8] Charles R Harris et al. "Array programming with NumPy". A: Nature 585.7825 (2020), pàg. 357 - 362.
- [9] Irwin Sobel i Gary Feldman. A 3x3 isotropic gradient operator for image processing. Inf. tèc. 671. Stanford University Artificial Intelligence Project (SAIL), 1968.
- [10] Fips Pub. "Secure hash standard (shs)". A: Fips pub 180.4 (2012).
- [11] Stuart P Lloyd. "Least squares quantization in PCM". A: IEEE transactions on information theory 28.2 (1982), pàg. 129 - 137.
- [12] Alexander G Nikolaev i Sheldon H Jacobson. "Simulated annealing". A: Handbook of metaheuristics (2010), pàg. 1 - 39.

9 Apèndix

9.1 Comparació Imatges generades vs Neuron Feature




Figura 34: Comparació Imatges generades vs NF Layer 0




Figura 35: Comparació Imatges generades vs NF Layer 1




Figura 36: Comparació Imatges generades vs NF Layer 2




Figura 37: Comparació Imatges generades vs NF Layer 3




Figura 38: Comparació Imatges generades vs NF Layer 4



Figura 39: Comparació Imatges generades vs NF Layer 5

9.2 Enllaç al codi del projecte

Enllaç al repositori GitHub amb el codi del projecte:

<https://github.com/Victorbs18/Understanding-Convolutional-Neural-Networks>